

Projeto 1

Equipe: Claudio Code

276617 Lucas Henrique Bertanha

281289 Leonardo Ferreira

281255 João Gabriel Lucena

249798 João Murilo Coutinho Martins

247059 Elton Aquino de Brito Filho

<https://github.com/4wardAerial/mc896>

- Feito num notebook python;
- Pode escolher qual caso usar mudando a linha do csv que é lida;
- Grafo em mermaid gerado no final.

```
df_nodes, df_edges = process_multicare_dataset(df_merged.iloc[22], lookup)
df_nodes.to_csv("../data/processed/nodes.csv", index=False)
df_edges.to_csv("../data/processed/edges.csv", index=False)
print(f"Extração em lote concluída! {len(df_nodes)} nós e {len(df_edges)} arestas criadas.")
```

[10] ✓ 0.5s


... Extração em lote concluída! 6 nós e 5 arestas criadas.

```
from IPython.display import display, Markdown

mermaid_md = to_mermaid(df_nodes, df_edges)
display(Markdown(f"``mermaid\n{mermaid_md}\n``"))
```

[12] ✓ 1.4s

...



Quais são os dados interessantes para serem extraídos e como?

Diagnóstico, Sintomas, Exames e Tratamento:

- Uso de uma **Lookup Table**;
- Checamos se cada token está na tabela.

Resultado do Exame:

- Usamos uma expressão **Regex** para procurar números após encontrarmos um token de Exame.

```

def build_gazetteer():
    return {
        'Diagnosis': ['diabetes mellitus', 'hypertension', 'acute pancreatitis', 'chronic
        'acute respiratory distress syndrome', 'sepsis', 'septic shock', 'pneumonia',
        'ischemic stroke', 'hemorrhagic stroke', 'acute kidney injury', 'chronic kidn
        'cholangitis', 'biliary obstruction', 'appendicitis', 'peritonitis', 'gastroi
        'deep vein thrombosis', 'venous thromboembolism', 'anemia', 'thrombocytopenia
        'metastatic disease', 'meningitis', 'encephalitis', 'pyelonephritis', 'urinar
        'arrhythmia', 'atrial fibrillation', 'valvular disease', 'endocarditis', 'per
    ],
        'Symptom': ['epigastric pain', 'nausea', 'fever', 'epigastric tenderness', 'fat s
        'abdominal pain', 'vomiting', 'diarrhea', 'constipation', 'bloody stools', 'h
        'chest pain', 'palpitations', 'dizziness', 'syncope', 'fatigue', 'weakness',
        'swelling', 'edema', 'leg swelling', 'lower extremity edema', 'jaundice', 'da
        'insomnia', 'restlessness', 'anxiety', 'depression', 'tremor', 'muscle weakne
        'sore throat', 'hoarseness', 'hemoptysis', 'cyanosis', 'hematuria', 'dysuria'
        'heat intolerance', 'blurred vision', 'visual disturbance', 'vertigo', 'pares
        'productive cough', 'nonproductive cough', 'dysphagia', 'odynophagia', 'hiccu
        'night sweats', 'burning sensation', 'pressure sensation', 'abdominal distens
        'polyuria', 'excessive thirst', 'hyperglycemia symptoms', 'hypoglycemia sympt
    ],
        'Exam': [
            'computed tomography', 'ct', 'thoracic ct', 'endoscopic ultrasound', 'eus', 'ul
            'hemoglobin', 'hematocrit', 'white blood cell count', 'total leukocyte count',
            'reticulocyte count', 'haptoglobin', 'adamts13 activity', 'c-reactive protein',
            'ferritin', 'lactate dehydrogenase', 'ldh', 'complement c3', 'complement c4',
            'mean gradient', 'nt-probnp', 'heart rate', 'blood pressure', 'mean arterial bl
            'immunoglobulin g', 'igm', 'igg', 'igg levels', 'forced vital capacity', 'fvc',
            'carcinoembryonic antigen', 'cea', 'pd-11 tps score', 'hydroxychloroquine level'
        ],
        'Treatment': [
            'intravenous fluids', 'oral rehydration', 'analgesia', 'analgesics', 'pain co
            'antibiotics', 'antiviral therapy', 'antifungal therapy', 'antiparasitic ther
            'anticoagulation', 'antiplatelet therapy', 'heparin', 'warfarin', 'enoxaparin
            'insulin', 'metformin', 'glucose control', 'blood pressure control', 'antihyp
            'fluid resuscitation', 'electrolyte replacement', 'oxygen therapy', 'ventilat
            'corticosteroids', 'prednisone', 'hydrocortisone', 'dexamethasone', 'steroid
            'immunosuppressive therapy', 'plasma exchange', 'plasmapheresis', 'intravenou
            'chemotherapy', 'radiotherapy', 'targeted therapy', 'immunotherapy', 'hormona
            'surgery', 'laparotomy', 'laparoscopy', 'resection', 'drainage', 'debridement
            'endoscopic drainage', 'cystgastrotomy', 'gastrojejunostomy', 'stent placeme
            'dialysis', 'renal replacement therapy', 'liver transplant', 'kidney transpla
            'blood transfusion', 'platelet transfusion', 'erythrocyte transfusion',
            'physical therapy', 'rehabilitation', 'respiratory physiotherapy', 'occupatio
            'bronchodilator therapy', 'inhaled beta agonist', 'nebulized therapy', 'smoki
            'prophylactic antibiotics', 'empiric therapy', 'supportive care', 'palliative
            'nutritional support', 'enteral nutrition', 'parenteral nutrition', 'oral nut
            'thrombolysis', 'vasopressor support', 'inotropic support', 'antiemetics', 'a
            'antihistamines', 'acid suppression', 'proton pump inhibitor', 'ppi', 'antaci
            'beta-blocker therapy', 'statin therapy', 'aspirin', 'ibuprofen', 'acetaminop
            'antidepressant therapy', 'antiepileptic therapy', 'antiarrhythmic therapy',
            'vaccination', 'immunization', 'monitoring', 'observation', 'watchful waiting
        ]
    }

```

Gazetteer
para



Lookup
Table

```

diabete      -> ('Diagnosis', 'type 2 diabetes')
mellitu      -> ('Diagnosis', 'diabetes mellitus')
hypertension -> ('Symptom', 'hypertension symptoms')
acute        -> ('Diagnosis', 'acute liver failure')
pancreatiti  -> ('Diagnosis', 'chronic pancreatitis')
chronic      -> ('Diagnosis', 'chronic kidney disease')
pancreatic   -> ('Diagnosis', 'pancreatic pseudocyst')
pseudocyst   -> ('Diagnosis', 'pseudocyst')
solid        -> ('Diagnosis', 'solid mass')
ma           -> ('Diagnosis', 'solid mass')
type         -> ('Diagnosis', 'type 2 diabetes')
2            -> ('Diagnosis', 'type 2 diabetes')
tumor        -> ('Diagnosis', 'tumor')
cancer       -> ('Diagnosis', 'cancer')
respiratory  -> ('Treatment', 'respiratory physiotherapy')
distre       -> ('Diagnosis', 'acute respiratory distress syndrome')
syndrome     -> ('Diagnosis', 'acute respiratory distress syndrome')
sepsi        -> ('Diagnosis', 'sepsis')
septic       -> ('Diagnosis', 'septic shock')
shock        -> ('Diagnosis', 'septic shock')
pneumonia    -> ('Diagnosis', 'pneumonia')
pulmonary    -> ('Diagnosis', 'pulmonary embolism')
embolism     -> ('Diagnosis', 'pulmonary embolism')
heart        -> ('Exam', 'heart rate')
failure      -> ('Diagnosis', 'respiratory failure')
congestive   -> ('Diagnosis', 'congestive heart failure')
myocardial   -> ('Diagnosis', 'myocardial infarction')
infarction   -> ('Diagnosis', 'myocardial infarction')
ischemic     -> ('Diagnosis', 'ischemic stroke')
stroke       -> ('Diagnosis', 'hemorrhagic stroke')

```

Lista tirada da Wikipedia

```
r '\d+(?:\.\d+)?(?:\s*x\s*10\d*)?'
```

Inteiros e, opcionalmente, decimais e representação científica

```
valid_units = {'u/l', 'mg/l', 'ng/ml', 'mmol/l', 'g/dl', '%', 'au/ml', 'mmhg', 'l'}
```

Unidades de medida

Regex usado para resultados do Exame, igual ao usado na tokenização.

Aplicado assumindo o formato:

Exame -> Resultado Numérico -> Unidade de medida

Estratégias clássicas utilizadas

Lookup Table (já mencionado)

Tokenização

```
token_re = re.compile(r"""
```

```
\d+(?:\.\d+)?(?:\s*x\s*10\d*)?
```

Novamente, inteiros e, opcionalmente, decimais e representação científica

```
|[a-zA-ZÀ-ÿ]+
```

Sequências de letras (palavras)

```
|[.,;:!?()%/]
```

Um caractere de pontuação

```
""", re.VERBOSE)
```

Ignora espaços em branco

Stemming

```
re.compile(r'(?<!s)s$').sub('', tok.lower())
```


Tira "s" do final, mas não "ss"

Visualização do Fluxo de Informação

Nós saindo dos pacientes conectam-se a informações específicas, mapeando o caso clínico:

- **Nós** do Paciente conectam-se aos dados relevantes associados àquele caso;
- **Arestas** de Conexão explicitam a relação lógica e semântica com o nó de destino.


- DIAGNOSED_WITH
- HAS_SYMPTOM
- UNDERWENT_EXAM
- TREATED_BY
- HAS_RESULT




Trecho do paciente: PMC4835621

...diagnostic tests revealed a white blood cell count of 6100 per microliter with 73% neutrophils, hemoglobin of 11.3 g/dL with a mean corpuscular volume (MVC) 94 femtoliters, and a reticulocyte count of 2.4%. Thrombocytes levels...

- Identificou dois Exames e acertou um dos resultados
- Grafo ficou extenso e teve “profundidade”






Trecho do paciente: PMC4630775

...a leathery appearance of the skin to the right dorsal hand and circumferential forearm with frank ischemia to the thumb. What are the causes of neonatal compartment syndrome? What factors (maternal or neonatal) correlate...

- Tokenização na Lookup Table criou a relação “of -> Loss of appetite”
- Grafo ficou pequeno e nem teve a profundidade com resultado de exames

Problemas da abordagem

- Não remoção de stop-words;
- Lookup Table tem muita influência no modelo;
- Semântica apenas para resultado do exame;
- Não identifica negação.



Conclusão
