Projeto 2

Equipe: Claudio Code

276617	Lucas Henrique Bertanha
281289	Leonardo Ferreira
281255	João Gabriel Lucena
249798	João Murilo Coutinho Martins
247059	Elton Aquino de Brito Filho

https://github.com/4wardAerial/mc896

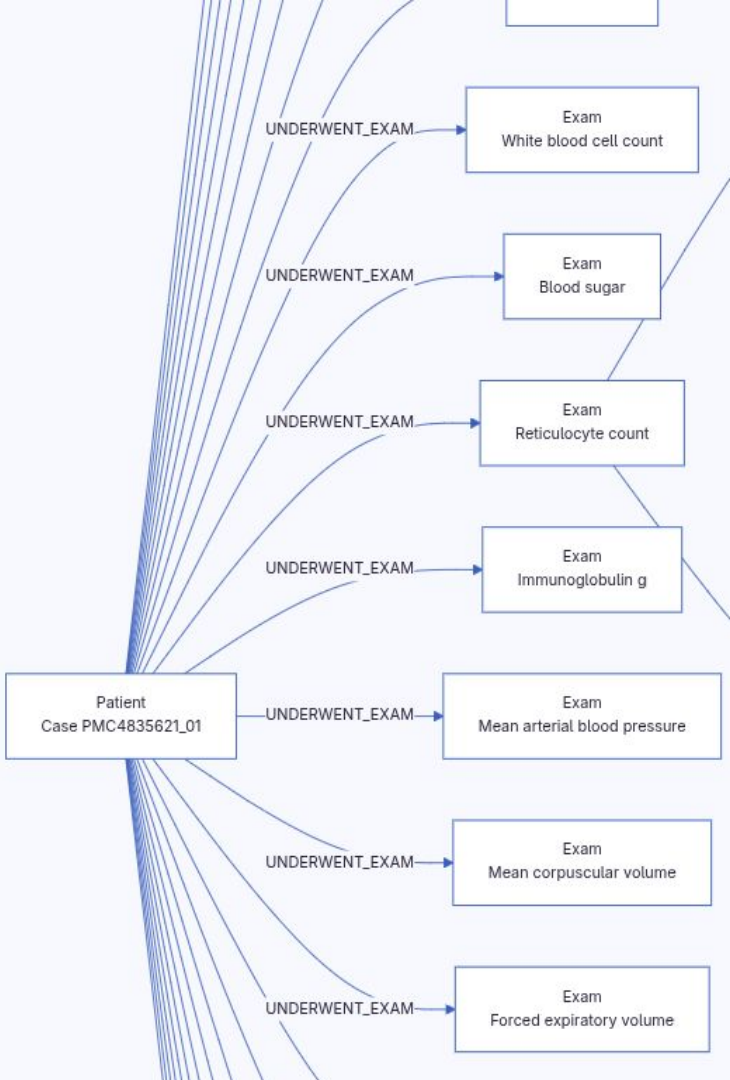
Evolução da Abordagem

Problemas no Projeto 1 (imagem ao lado):

- Não remoção de stop-words.
- Lookup Table com influência excessiva (ex: "*of*" virando diagnóstico).
- Semântica limitada apenas a resultados de exames.

Soluções investigadas no Projeto 2:

- Representações baseadas em N-gramas.
- Métodos de aprendizado de máquina clássico (CRF e Regressão Logística).
- Supervisão fraca para aprimorar o reconhecimento de entidades.



Pipeline do projeto

Parte 1, Dados e split:

- Faz uma divisão dos casos: 20% para teste (11), 80% para treino (45).
- Divisão considera casos do mesmo artigo como um grupo só, para evitar vazamento.

Parte 2, Reconhecimento por gazetteer:

- Tokenização, stemming e segmentação de sentenças por regex (1199 sentenças de treino e 257 de teste).
- Assim como no projeto 1, um dicionário é criado a partir do gazetteer:

  (stem) -> (tipo, termo original)

  A diferença agora é o *matcher* que usa uma janela de 4, 3, 2 e 1 tokens, registrando a entidade achada na maior janela.

Laboratory investigations showed an elevated erythrocyte sedimentation rate of 120 mm/h, C-reactive protein of 91 mg/dl, a white blood cell count of 28,000/mm3 and normal platelet count as well as hemoglobin of 6 g% for which she received blood transfusion.

Trecho encontrado	Janela vencedora	Tipo
erythrocyte sedimentation rate	3 tokens	Exam
C-reactive protein	2 tokens	Exam
white blood cell count	4 tokens	Exam
blood transfusion	2 tokens	Treatment

```
 {'case_id': 'PMC9387390_01',
  'article_id': 'PMC9387390',
  'sid': 6,
  'text': 'Approximately 11 months after the
initiation of chemotherapy, he presented to the
hospital with nausea, emesis, and abdominal
distention.',
  'tokens': [('Approximately', 0, 13),
   ...
   ('the', 30, 33),
   ('initiation', 34, 44),
   ('of', 45, 47),
   ('chemotherapy', 48, 60),
   (',', 60, 61),
   ...
   ('with', 91, 95),
   ('nausea', 96, 102),
   (',', 102, 103),
   ('emesis', 104, 110),
   (',', 110, 111),
   ('and', 112, 115),
   ...
   ('.', 136, 137)],
  'gold': [(7, 8, 'Treatment', 'chemotherapy'),
(15, 16, 'Symptom', 'nausea')],
  'rules': [(15, 16, 'Symptom', 'nausea')]},
```

- São feitos dois *matcher* de entidades, o ‘gold’, que usa o gazetteer completo e o ‘rules’, que usa o reduzido (sem 25% dos termos) para um experimento de generalização.

Exemplo de um dicionário gerado para uma sentença, com termos que deram *match* com gazetteer completo e com o reduzido no final

Parte 3, Extração de Conhecimento com N-Gramas

N-gramas capturam o vocabulário médico através da probabilidade condicional (NPMI).

N-Grama	Tamanho	Contagem	NPMI
computed tomography	2	13	0.981
pleural effusion	2	7	0.953
spontaneous respiration	2	15	0.945
intensive care unit	3	6	0.908

Parte 4, NER com CRF e Supervisão Fraca

Treinamento do modelo CRF utilizando os rótulos do gazetteer reduzido.

Objetivo: CRF aprender a etiquetar

1. Converte ‘rules’ em BIO (*Begin*, *Inside*, *Outside*); cada sentença vira uma sequência de etiquetas (B-Symptom, I-Symptom, O-...) para servir de resposta certa do treino.

2. Extrair características de cada *token*: um dicionário com a palavra, stem, sufixos, ortografia e vizinhos (janela de +/- 2).

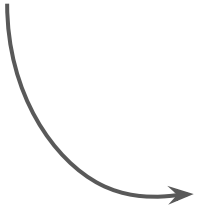
```
{'bias': 1.0, 'w': 'three', 'stem': 'three', 'suf2': 'ee', 'suf3': 'ree', 'suf4': 'hree',
'pre3': 'thr', 'digit': False, 'title': False, 'upper': False, 'hyph': False, 'first':
False, 'w[-2]': '<BOS>', 'w[-1]': 'approximately', 'w[1]': 'months', 'w[2]': 'later'}
```

3. Treina o CRF para maximizar a semelhança da predição com o conjunto de etiquetas feita a partir de 'rules'.

4. Com o CRF treinado, as *features* dos tokens de teste são passados e ele tenta prevê-los. Cada span previsto é comparado com o do 'gold':

- Se estava no 'gold', conta como TP; senão, FN.
- Se não estava no 'gold', conta como FP.

5. Repetimos o processo incluindo unigramas, depois uni+bigramas, depois uni+bi+trigramas e por fim uni+bi+trigramas+PMI.



Era esperado que o modelo aprendesse que conjuntos de palavras têm significado mais forte que elas soltas

Como a avaliação é contada

O span previsto precisa bater com o gold em início, fim e tipo

- **TF:** span previsto idêntico a um span gold
- **FN:** span gold que o modelo não previu
- **FP:** span previsto que não existe no gold

Micro-média: somamos TP, FP, FN das 257 sentenças e então calculamos:

$$P = \frac{TP}{TP + FP} \qquad R = \frac{TP}{TP + FN} \qquad F1 = \frac{2PR}{P + R}$$

- O F1 por tipo usa os mesmos contadores (separados por Diagnosis, Symptom, Exam, Treatment)
- recall_unseen_terms - recall calculado só sobre os spans gold de termos escondidos.

modelo	precision	recall	f1	recall_unseen_terms	n_unseen_gold	f1_Diagnosis	f1_Symptom	f1_Exam	f1_Treatment
Regras (Parte 1, léxico reduzido)	1.000	0.858	0.924	0.0	20	1.000	0.925	0.939	0.837
CRF uni	0.874	0.539	0.667	0.0	20	0.824	0.844	0.532	0.684
CRF uni+bi	0.872	0.532	0.661	0.0	20	0.824	0.844	0.519	0.684
CRF uni+bi+tri	0.869	0.518	0.649	0.0	20	0.824	0.825	0.505	0.684
CRF uni+bi+tri+PMI	0.878	0.511	0.646	0.0	20	0.750	0.825	0.509	0.684

- **Melhor configuração**: Características de Unigrama.
- **Desempenho (F1-Score)**: 0.667 no conjunto de teste.

Tipo	Entidade Proposta
Exam	hemoglobin
Symptom	finger pain
Exam	blood count

Modelo propôs entidades novas (os Falso Positivos)

Parte 5, Classificação de Relações

Uso de modelos lineares e TF-IDF para identificar relações entre entidades na mesma sentença.

- **Modelo Superior**: Regressão Logística (N-gram max = 1).
- **Macro F1**: 0.444.
- **F1 Ponderado**: 0.948.

Novos Gatilhos (ML vs Regras):

Exemplo descoberto pelo modelo (confiança 0.76):

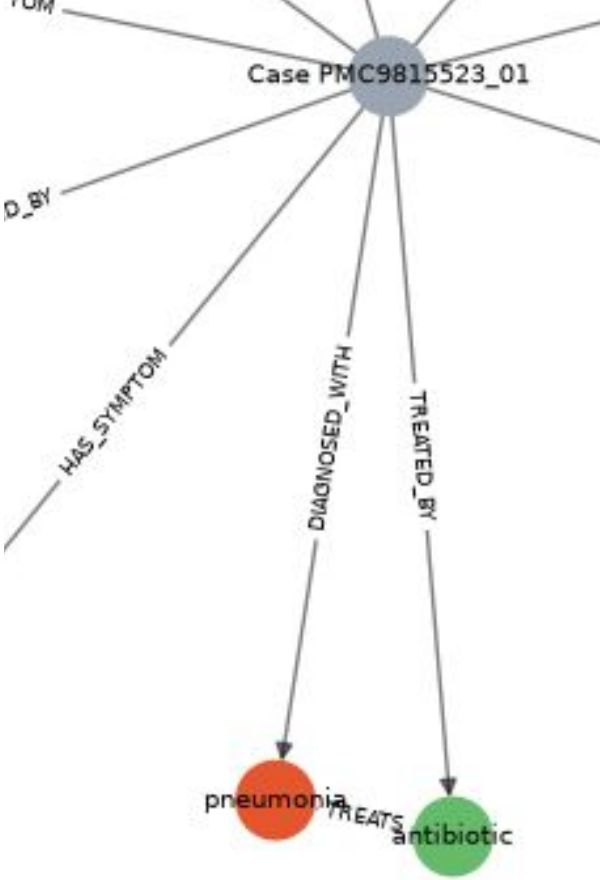
```
[pneumonia] -> "that required" -> [antibiotic] = TREATS
```

Parte 5, Classificação de Relações

Modelo	N_gram_max=1	N_gram_max=2	N_gram_max=3
ComplementNB	0.389	0.389	0.389
LinearSVC	0.222	0.222	0.222
LogReg	0.444	0.444	0.444



Parte do grafo do caso PMC9815523_01 usando Regras



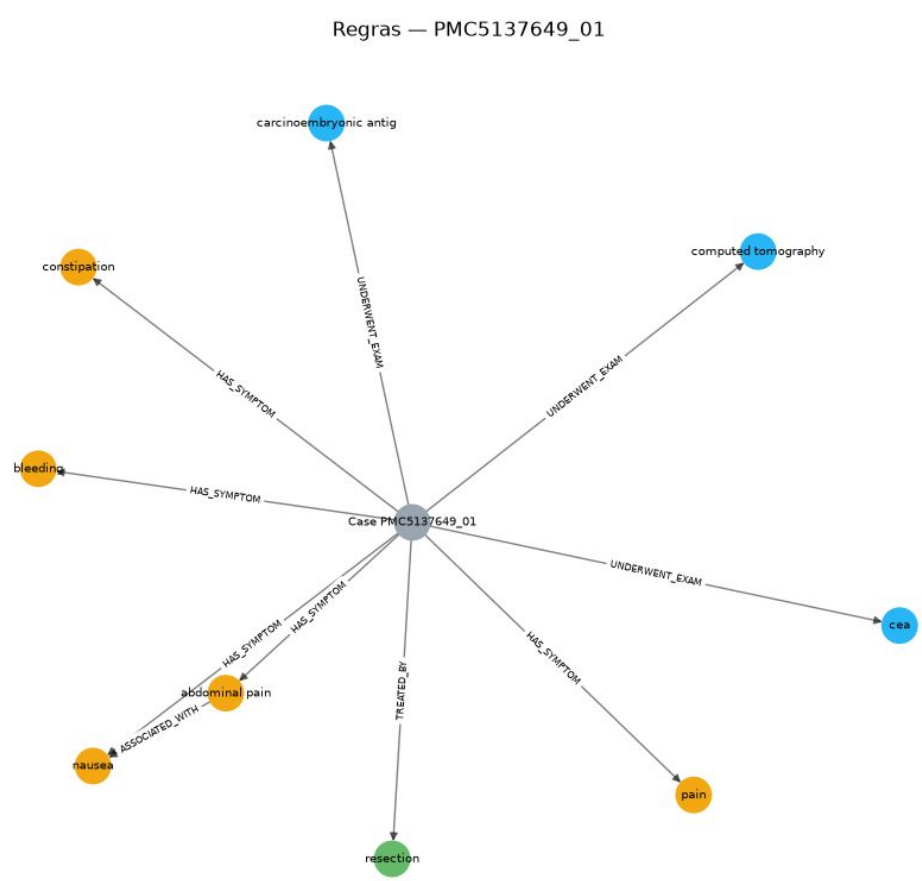
Parte do grafo do caso PMC9815523_01 usando ML

Parte 6, Comparativo por Grafo de Conhecimento

Comparação estrutural entre o grafo gerado por Regras e o gerado por Machine Learning:

Métrica	Regras (Parte 1)	Machine Learning
Nós de Entidade	73	60
Arestas Paciente → Entidade	94	80
Arestas Entidade ↔ Entidade	3	2
Grau Médio	2.24	2.25

Similaridade Jaccard (Nós de Entidade): 0.662


Regras — PMC5137649_01
carcinoembryonic antig
constipation
computed tomography
bleeding
Case PMC5137649_01
cea
abdominal pain
nausea
pain
resection
UNDERWENT_EXAM
HAS_SYMPTOM
TREATED_BY
ASSOCIATED_WITH


ML — PMC5137649_01
cea
computed tomography
carcinoembryonic antig
pain
Case PMC5137649_01
resection
abdominal pain
nausea
bleeding
UNDERWENT_EXAM
HAS_SYMPTOM
TREATED_BY
ASSOCIATED_WITH

Limitações da abordagem

- Ainda não tem entendimento de negação:

"*no evidence of bleeding*" vira "HAS_SYMPTOM bleeding"

- Sem normalização de sinônimos:

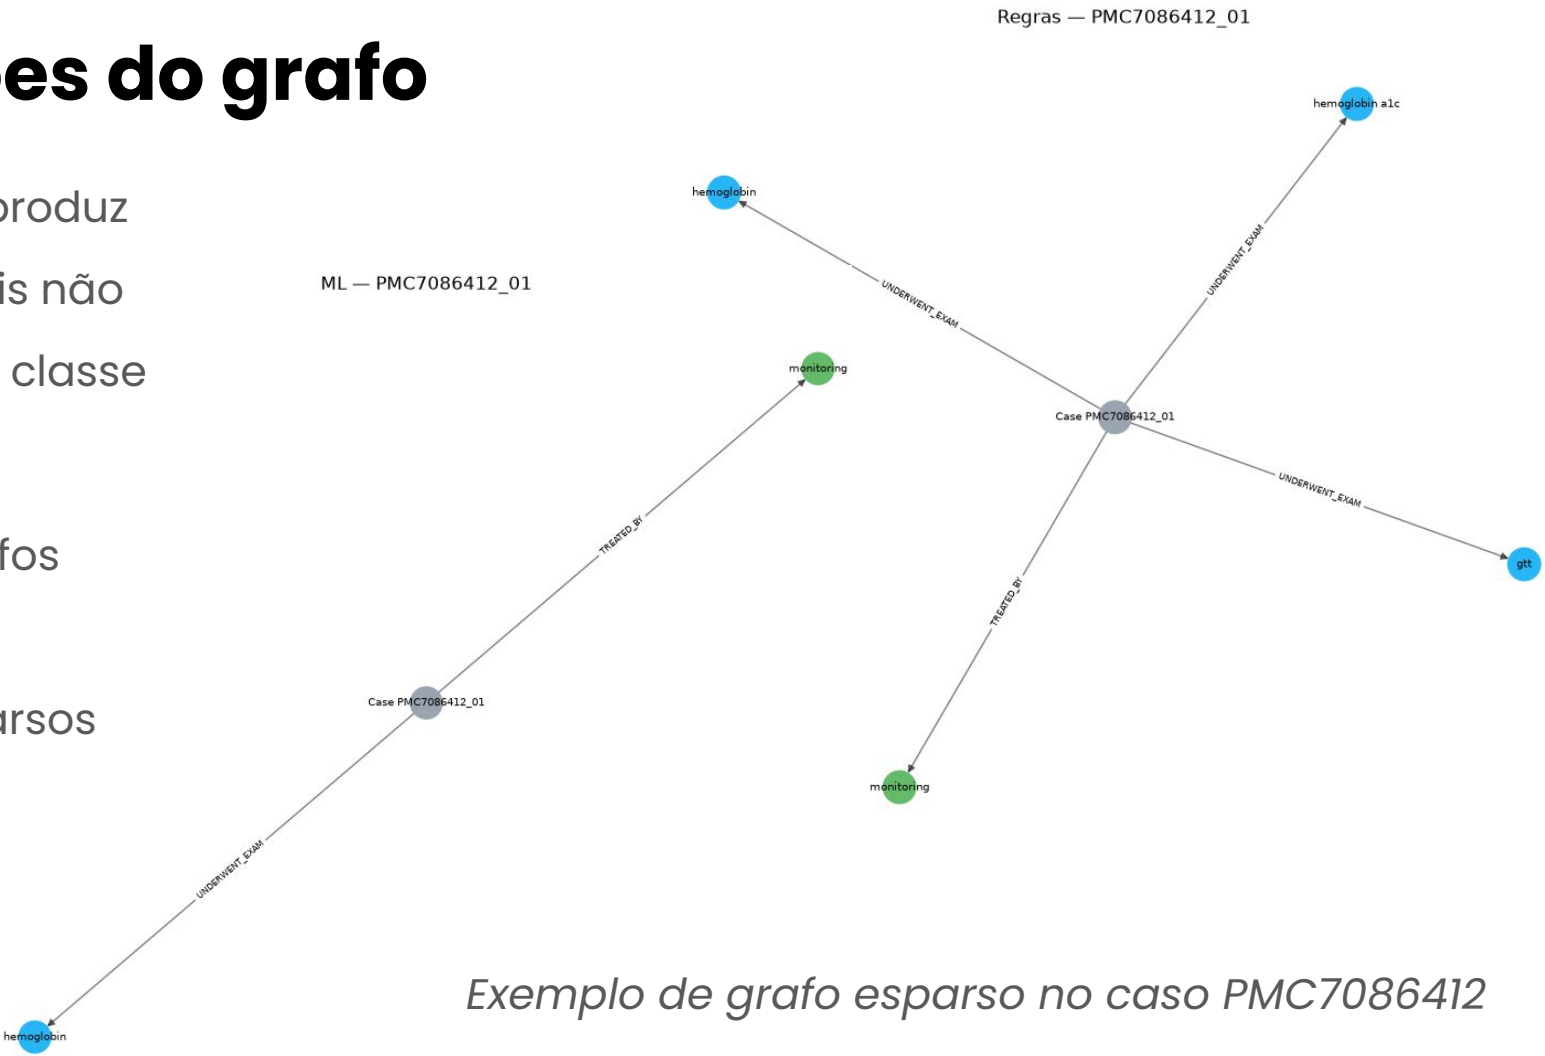
CT e *computed tomography*, *ESR* e *erythrocyte sedimentation rate* são nós separados.

- Valores numéricos frágeis:

12,476.5 ng/ml vira *476.5 ng/ml* (a vírgula de milhar quebra o número)

Limitações do grafo

- ML nunca produz CAUSES pois não existe essa classe no treino
- Alguns grafos continuam muito esparsos



Exemplo de grafo esparso no caso PMC7086412

Conclusão